迷你搜索引擎项目

测试报告 01：单元测试

Catch2 单元测试与 CTest 集成测试

版本 1.0　测试日期 2026-10-19

报告编号	TR-01
被测对象	迷你搜索引擎（C++17，`mse`）
被测版本	分支 `test/reports`，基于 `origin/main` 加注释与测试改动
测试环境	WSL2（Linux 6.18），g++ 15.2，CMake 3.31.6，Release
测试日期	2026-10-19
总体结论	8 个单元测试可执行文件、18 项 CTest 全部通过

1　目标与范围

本报告覆盖项目的**单元测试**与 **CTest 集成测试**，回答两个问题：

1. 每个模块的行为是否符合第 2 章规格（分词、词干化、词典、索引、查询、停用词、计数、B+Tree）；
2. 把模块组合成完整管线后，索引构建、v1/v2 序列化、磁盘词典与独立对拍是否仍能通过。

不包含：阈值实验的统计结果（见 TR-03）、大规模语料的性能与外推（见 TR-04）、以及独立 Python 对拍的逐项数据（见 TR-02）。三份报告合起来构成完整测试证据链。

2　测试环境与构建

```
cmake -S . -B build -DCMAKE_BUILD_TYPE=Release
cmake --build build -j
ctest --test-dir build --output-on-failure
```

单元测试使用项目内 vendored 的 Catch2 v3（amalgamated 单文件）。Catch2 只链接测试可执行文件，不进入 `mse` 交付二进制；测试代码启用与主代码相同的警告选项。

表 1: 测试环境

项目	值
操作系统	WSL2，Linux 6.18.54.1-microsoft-standard-WSL2
编译器	g++ 15.2，`-std=c++17`
构建系统	CMake 3.31.6，Release
测试框架	Catch2 v3（vendored）
测试驱动	CTest 3.31.6
语料	`data/`（莎士比亚，195 文档）与 `data2/`（RFC，3 文档）

3 单元测试结果

八个测试可执行文件共 **46 个 TEST_CASE**、**85,155 条断言**，全部通过。断言数最多的是 `test_bptree`，因为它对每个键与 `std::map` oracle 逐项比较；断言数大不代表用例多，而是每个键的读、写、范围扫描都被显式核对。

表 2: 单元测试汇总

测试文件	TEST_CASE	断言数	结果
`test_tokenizer`	2	24	通过
`test_stemmer`	7	101	通过
`test_dict`	6	50	通过
`test_index`	8	248	通过
`test_query`	7	26	通过
`test_stopwords`	3	11	通过
`test_count`	3	47	通过
`test_bptree`	10	84,648	通过
合计	46	85,155	全部通过

4 各套件覆盖内容

4.1 分词器（test_tokenizer）

两个用例分别覆盖纯文本分词与整文档分词：

- 标点、数字、撇号与连字符的切分边界；
- 标题行、舞台指示行、说话人行的识别，以及 `--keep-headings` / `--keep-speakers` / `--keep-stage` 三个开关；
- 位置编号从 0 开始、只对保留 token 递增；

- 文本层中“以 [开头但实为台词”的行不会被误判为标题行。

4.2 词干化（test_stemmer）

七个用例按 Porter 算法的步骤组织：

- 步骤 1a/1b/1c：复数、`-ed/-ing`、词尾 `y`；
- 步骤 2：双后缀映射为单后缀；
- 步骤 3：`-icate/-ative/-alize`；
- 步骤 4：残余后缀；
- 步骤 5a/5b：词尾 `-e` 与双 `-ll`；
- 收缩词预处理（`isn't`、`you'll` 等）；
- 不应变化的词（短词、专名、已被词干化的形式）。

与 canonical C 实现和 NLTK `MARTIN_EXTENSIONS` 的逐词对拍不在本报告，见 TR-02；本套件只验证单元级规则。

4.3 词典（test_dict）

六个用例覆盖三种实现（伸展树、哈希、`std::map`）：

- 伸展树：最后访问的词位于根，插入触发旋转；
- 哈希：增长过程中发生 rehash，桶数按预期变化；
- 三套“行为脚本”对同一条操作序列给出一致结果；
- 20,000 次随机插入/查询工作负载下，splay 与 hash 的词表完全一致。

4.4 索引（test_index）

八个用例覆盖构建、序列化和不变量：

- 讲义四文档黄金样例的 posting 表；
- splay 与 hash 构建出的索引文件逐字节一致；
- v1 序列化往返、加载校验、损坏文件必须报错；
- v2 压缩索引往返、体积下降、独立解码；
- varint 的 6/14/22/30 位四个长度档及截断拒绝；
- 停用词版本中词项消失、positions 重新编号；
- 块式构建与内存构建逐字节一致；

- B+Tree sidecar 能解析全部词项而不加载 term 表。

4.5 查询（test_query）

七个用例覆盖三种查询模式与四个阈值：

- 单词查询的 tf 排序、归一化、未命中；
- 短语查询在过滤后 token 流上的相邻性；
- 布尔查询的 `--min-match` 语义与得分排序；
- `--max-df`/`--min-df`/`--top-x` 的丢弃与截断；
- 停用词查询：原始索引可查，过滤索引返回空并给出 note；
- 词干化使不同词形命中同一词干；
- `--pretty` 能把命中 position 映射回源行。

4.6 停用词（test_stopwords）

三个用例覆盖：

- 39 个结构词全部在表中；
- 内容词与古语词保留，不被误删；
- 缺失文件时报错并打印路径。

4.7 计数与熵（test_count）

三个用例覆盖：

- golden4 上按公式手算的熵值与程序输出一致；
- `deriveStopWords` 的三特征规则在边界上的取舍；
- plain 格式文档中“看起来像标记行”的文本仍可检索。

4.8 B+Tree（test_bptree）

十个用例覆盖内存树与磁盘页文件：

- 与 `std::map` oracle 逐键比较（三档页宽、对抗性同前缀键）；
- 单条插入与 bulk-load 的查询结果一致；
- 重复键的 upsert 语义（覆盖值、不增键）；
- 空树、单元素树、范围扫描、叶链顺序；

- `writeFile` + `BTreeFile` 往返、缓存计数、坏魔数拒绝；
- 输入契约（未排序输入、超长键）必须报错。

5 CTest 集成结果

CTest 注册 18 项测试：8 个单元测试、2 个语料冒烟测试、8 个对拍/压缩/磁盘词典测试。全部通过，总耗时约 47.7 秒。

表 3: CTest 测试清单与结果

#	名称	内容	结果
1	`test_tokenizer`	分词器单元测试	通过
2	`test_stemmer`	Porter 词干化单元测试	通过
3	`test_dict`	三种词典实现	通过
4	`test_index`	索引构建/序列化/不变量	通过
5	`test_query`	查询模式与阈值	通过
6	`test_stopwords`	停用词表	通过
7	`test_count`	tf/df/熵与派生规则	通过
8	`test_bptree`	内存树与磁盘页文件	通过
9	`mse_stats`	语料仍为 195 文档	通过
10	`rfc_stats`	第二语料仍为 3 文档	通过
11	`crosscheck_build`	构建 v1 + B+Tree sidecar	通过
12	`crosscheck_brute_force`	Python 全词表对拍 v1	通过
13	`crosscheck_phrases`	303 条短语对拍 v1	通过
14	`crosscheck_dictfile`	磁盘词典全词表校验	通过
15	`crosscheck_compress_build`	构建 v2 + sidecar	通过
16	`crosscheck_compress`	Python 全词表对拍 v2	通过
17	`crosscheck_compress_dictfile`	v2 磁盘词典校验	通过
18	`crosscheck_compress_phrases`	303 条短语对拍 v2	通过

6 单元测试发现的问题

单元测试与集成测试在开发过程中抓出了多个实现问题，其中与模块行为直接相关的代表性问题如下（完整清单见 TR-02 第 6 节）：

表 4: 单元/集成测试发现并修复的问题

#	问题	修复
1	伸展树插入分支保留 `Node*&` 引用，旋转后引用悬垂，插入后段错误	先把新节点指针复制到局部变量，再 splay
2	`Reader` 构造时传入临时 vector，整句结束后引用悬垂，加载误报截断	先把文件内容存入具名变量
3	`MapDictionary::sortedEntries()` 只填 map 键，`TermEntry::term` 为空	插入后同步 `term` 字段；随机对拍抓住
4	B+Tree 内层借用插入错误的分隔键，30M/50M 键时报 I2 违反	用原 `last` 的首键作为边界
5	B+Tree 变长键按条数分裂，50% 字节填充不变量被破坏	改为合法窗口内的字节中点分裂

这些问题说明：仅靠“跑通主流程”不够，必须让结构不变量和跨实现对拍主动失败，才能暴露悬垂引用、分隔键语义和字节预算这类边界错误。

7 复现方式

```
# 全部测试
ctest --test-dir build --output-on-failure

# 单个套件
./build/test_bptree
./build/test_index
./build/test_query --list-tests

# 只跑 Python 对拍
ctest --test-dir build -R crosscheck --output-on-failure
```

若系统没有 Python 3，CMake 会跳过 8 项对拍测试，但 8 个单元测试与 2 个冒烟测试仍会执行。

8 结论

- 8 个模块、46 个 TEST_CASE、85,155 条断言全部通过；
- 18 项 CTest 全部通过，覆盖单元行为、语料冒烟、v1/v2 对拍、磁盘词典与短语查询；
- 测试发现的 5 类代表性问题均已修复并有回归用例；
- 单元测试只证明模块行为，跨实现正确性证据见 TR-02，阈值与规模证据见 TR-03/TR-04。