迷你搜索引擎项目

测试报告 03：查询阈值实验

四个阈值对结果集的影响（201 条测量）

版本 1.0　测试日期 2026-10-19

报告编号	TR-03
被测对象	`mse query` 的四个阈值
被测版本	分支 `test/reports`，基于 `origin/main` 加注释与测试改动
测试环境	WSL2（Linux 6.18），g++ 15.2，Python 3；正式索引（stopwords + stem）
测试日期	2026-10-19
总体结论	201 条测量全部完成；四类阈值的作用位置与副作用已量化

1　目标与范围

本报告量化 `mse query` 的四个阈值：

- `--max-df`：丢弃“太大众”的查询词；
- `--min-df`：丢弃太罕见的查询词；
- `--min-match`：布尔查询至少命中几个词；
- `--top-x`：只保留得分最高的前 x 篇文档。

实验回答三个问题：阈值把结果集改变了多少、改变发生在“词侧”还是“结果侧”、不同查询类型对阈值的敏感度是否相同。

2　方法

2.1　查询集

固定 15 条查询，覆盖 8 类查询意图（表 1）。查询集不随机生成：它覆盖高频词、中频词、低频词、专名、短语、含停用词的短语、布尔组合与停用词，保证每个阈值都有可观察的边界。

表 1: 阈值实验的查询集

查询	类别	选择理由
`love`	high	df_ratio 0.71，高频内容词
`sweet`	high	df_ratio 0.46
`good`	mid	df_ratio 0.29
`night`	mid	df_ratio 0.29
`sword`	low	$df = 37$
`moon`	low	$df = 35$
`banquo`	name	$df = 1$，专名
`osric`	name	$df = 1$，专名
`king queen`	bool	两个中频词，AND 基线
`sweet sword moon`	bool	三个词，观察丢词后的“放宽”
`good night`	phrase	普通短语
`king richard`	phrase	结果较少的短语（7 篇）
`my lord`	phrase-stop	`my` 是停用词，短语退化
`the`	stopword	过滤索引中不可检索
`of`	stopword	过滤索引中不可检索

2.2 测量协议

每次只改变一个参数，其余阈值保持关闭（基线）。每条测量记录：

- 返回文档数；
- 与基线的 Jaccard 相似度 $J = |A \cap B| / |A \cup B|$；
- note 数（解释被丢弃的词、停用词等）；
- 查询耗时（毫秒）。

共 15 条基线 +75 条 `--max-df` +60 条 `--min-df` +6 条 `--min-match` +45 条 `--top-x` = **201** 条测量。原始数据保存在 `data/threshold_matrix.csv`，生成脚本为 `tools/threshold_matrix.py`。

3 结果

3.1 `--max-df`：丢弃“太大众”的词

表 2: `--max-df` 扫描（单元格为返回文档数）

查询	基线	0.9	0.7	0.5	0.3	0.1
love（0.71）	138	138	0	0	0	0
sweet（0.46）	90	90	90	90	0	0
good（0.29）	57	57	57	57	57	0
night（0.29）	56	56	56	56	56	0
sword（0.19）	37	37	37	37	37	0
moon（0.18）	35	35	35	35	35	0
banquo / osric（$df = 1$）	1	1	1	1	1	1
king queen	33	33	33	33	33	0
sweet sword moon	30	30	30	30	30	0
短语查询	7/23/42	7/23/42	7/23/42	7/23/42	7/23/42	7/23/42
the / of	0	0	0	0	0	0

3.2 `--min-df`：丢弃太罕见的词

表 3: `--min-df` 扫描

查询	基线	2	5	20	50
banquo / osric（$df = 1$）	1	0	0	0	0
sword（$df = 37$）	37	37	37	37	0
moon（$df = 35$）	35	35	35	35	0
king queen	33	33	33	33	0
sweet sword moon	30	30	30	30	90

注：最后一行在 `--min-df 50` 时丢弃了 `sword` 与 `moon`，只剩 `sweet`，结果从 30 篇增加到 90 篇；与基线的 Jaccard 为 0.33。

3.3 `--min-match`：布尔语义的松紧

表 4: `--min-match` 扫描（括号内为 Jaccard）

查询	基线（AND）	$k = 1$	$k = 2$	$k = 3$
king queen	33	43（0.77）	33	33
sweet sword moon	30	93（0.32）	39（0.77）	30

k 超过可检索词数时会被钳制为词数，不会返回空集。表中 $k = 3$ 对 `king queen`（两个词）等价于 AND。

3.4 `--top-x`：结果截断

表 5: `--top-x` 扫描（括号内为 Jaccard）

查询	基线	5	10	20
love	138	5（0.04）	10（0.07）	20（0.14）
good night	23	5（0.22）	10（0.43）	20（0.87）
king richard	7	5（0.71）	7（1.00）	7（1.00）
banquo / osric	1	1（1.00）	1（1.00）	1（1.00）

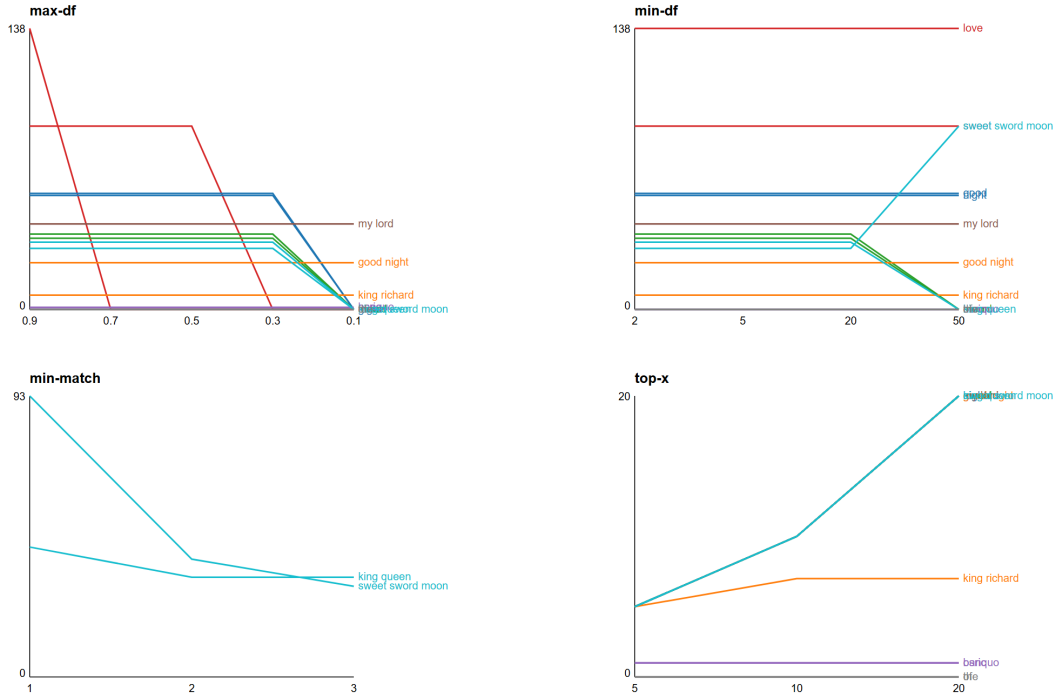


图 1: 阈值矩阵：每个面板一个参数，横轴为参数值，纵轴为返回文档数。

4 分析

1. **`--max-df` 直接消除高频词的结果**。单词查询一旦词被丢弃，结果从上百篇直接归零。`love` 在 0.7 档（df_ratio 0.71）被丢弃，`sweet` 在 0.3 档被丢弃。阈值必须按查询意图设定，不能一律取小。

2. **`--min-df` 与多词 AND 组合会产生“丢词即放宽”**。`sweet sword moon` 在 `--min-df 50` 下丢弃 `sword` 与 `moon`，只剩 `sweet`，结果从 30 篇增加到 90 篇，Jaccard 仅 0.33。原因是阈值作用于查询词，而不是直接作用于结果文档。

3. **`--min-match` 是布尔语义的旋钮。** $k = 1$ 即 OR，结果集显著扩大；$k =$ 词数 即 AND；超过词数时钳制，不会返回空集。
4. **`--top-x` 是纯结果侧截断。**它不改变匹配语义，Jaccard 随 x 单调回升；对结果数不超过 x 的查询没有影响。
5. **短语查询不受词侧阈值影响。** 7/23/42 三组短语结果在所有 `--max-df` 档位保持不变（Jaccard 恒 1.00）。这是设计行为：短语是整体，丢掉任何一个词都不再是原短语。
6. **停用词查询恒为空。**过滤索引中 `the/of` 没有 posting，与阈值无关；系统输出 note 解释原因。

5 复现方式

```
# 重新生成 201 条测量与图
python3 tools/threshold_matrix.py

# 产物
#   build/threshold_matrix.csv   原始测量
#   build/threshold_matrix.svg   图
```

CSV 列为 `query, category, mode, param, value, results, jaccard, notes, ms`。本报告使用的 CSV 副本在 `reports/data/threshold_matrix.csv`，可以直接用任意表格工具复查表 2–5。

6 结论与建议

- 四个阈值分别作用于“词侧”（`--max-df`、`--min-df`）、“匹配语义”（`--min-match`）和“结果侧”（`--top-x`），不能用同一个“召回率”口径解释；
- 默认配置应保持所有阈值关闭，让查询语义可预测；需要降噪时优先用 `--max-df`，但必须接受高频词查询归零；
- `--min-df` 与多词 AND 组合存在反直觉的“结果变多”现象，交互式系统应提示被丢弃的词；
- `--top-x` 适合展示层截断，不适合作为召回率优化手段；
- 短语查询应保持“整段匹配”，不要对短语应用词侧阈值。

结论：阈值不是“越小越好”的过滤器，而是改变查询语义的四个旋钮；本实验用 201 条测量给出了每个旋钮的作用位置和副作用。